

Prática Estatística II

Introdução

Este material serve como guia de apoio para apresentação do trabalho de Prática Estatística II.

O objetivo não é apenas decorar resultados, mas entender:

- o que cada método estatístico faz;
 - por que ele foi utilizado;
 - como interpretar os resultados;
 - quais conclusões podem ou não ser feitas.
-

Conceitos Fundamentais

O que é Estatística Descritiva?

A Estatística Descritiva é a etapa responsável por resumir e organizar os dados.

Ela NÃO testa hipóteses.

Ela serve para:

- entender o comportamento da amostra;
- visualizar padrões;
- identificar possíveis outliers;
- observar dispersão;
- analisar tendência central.

Exemplos utilizados no trabalho:

- média;
 - mediana;
 - desvio padrão;
 - histogramas;
 - boxplots;
 - tabelas resumo.
-

Média

O que é?

A média é uma medida de tendência central.

Representa o “centro” dos dados.

Fórmula

$$\bar{x} = \frac{\sum x_i}{n}$$

Interpretação

Média alta

Pode indicar:

- maiores valores de IMC;
- maior concentração dos dados em regiões superiores.

Média baixa

Pode indicar:

- menores valores médios;
 - distribuição deslocada para baixo.
-

Cuidados

A média é sensível a outliers.

Exemplo:

Uma pessoa com IMC extremamente alto pode puxar a média para cima.

Por isso:

- média sozinha não basta;
 - é importante analisar mediana e dispersão.
-

Mediana

O que é?

Valor central da distribuição.

Divide os dados ao meio.

Interpretação

Média próxima da mediana

Sugere distribuição mais simétrica.

Média muito diferente da mediana

Pode indicar:

- assimetria;
 - presença de outliers;
 - distribuição não normal.
-

Desvio Padrão

O que é?

Mede a dispersão dos dados.

Indica o quanto os valores variam em torno da média.

Fórmula

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

Interpretação

Desvio padrão pequeno

Dados mais concentrados.

Menor variabilidade.

Desvio padrão grande

Dados mais espalhados.

Maior variabilidade.

Homogeneidade vs Associação

Dados homogêneos NÃO significam associação

Esse é um ponto MUITO importante.

Homogeneidade

Relaciona-se à variabilidade.

Quando grupos possuem dispersões parecidas.

Exemplo:

- variâncias semelhantes;
 - comportamento semelhante das dispersões.
-

Associação

Relaciona-se à dependência estatística.

Exemplo:

- COVID associado ao delivery;
 - peso associado ao IMC.
-

Resumo

Homogeneidade: - compara dispersões.

Associação: - compara relação entre variáveis.

São conceitos completamente diferentes.

Homocedasticidade

O que é Homocedasticidade?

Homocedasticidade significa:

igualdade das variâncias entre grupos.

Exemplo

Comparar IMC entre grupos de atividade física.

Se todos os grupos tiverem variâncias parecidas:

há homocedasticidade.

O que é Heterocedasticidade?

Heterocedasticidade significa:

variâncias diferentes entre os grupos.

Interpretação prática

Se um grupo apresenta:

- IMCs muito concentrados;

e outro:

- IMCs muito espalhados;

então há heterocedasticidade.

Consequências da Heterocedasticidade

A ANOVA clássica assume:

$$\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$$

Se isso não ocorre:

- resultados podem ficar enviesados;
- o teste clássico pode não ser adequado.

Por isso foi usada:

- ANOVA de Welch.
-

p-valor

O que é p-valor?

O p-valor mede:

o quão compatíveis os dados observados são com a hipótese nula.

Interpretação do p-valor

Quando:

$$p < \alpha$$

Rejeitamos:

$$H_0$$

Ou seja:

há evidências estatísticas contra a hipótese nula.

Quando:

$$p > \alpha$$

NÃO rejeitamos:

$$H_0$$

Importante:

isso NÃO prova que H_0 é verdadeira.

Apenas significa:

não houve evidência suficiente para rejeitá-la.

Nível de significância

O que é α ?

É o nível de significância.

Representa o risco tolerado de erro tipo I.

Normalmente:

$$\alpha = 0.05$$

Erro Tipo I

O que é?

Rejeitar H_0 quando ela é verdadeira.

Falso positivo.

Teste de Shapiro-Wilk

O que ele faz?

Verifica normalidade.

Hipóteses

H_0 : os dados seguem distribuição normal

H_1 : os dados não seguem distribuição normal

Interpretação

Quando:

$$p < 0.05$$

Conclusão:

- rejeita normalidade;
 - indícios de distribuição não normal.
-

Quando:

$$p > 0.05$$

Conclusão:

- não há evidência contra normalidade.
-

Importância da Normalidade

Muitos métodos paramétricos assumem:

- distribuição aproximadamente normal.

Exemplos:

- ANOVA clássica;
 - regressão linear;
 - testes t.
-

Teste de Levene

O que ele faz?

Verifica igualdade das variâncias.

Hipóteses

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$$

H_1 : pelo menos uma variância difere

Interpretação

Quando:

$$p < 0.05$$

Conclusão:

- há heterocedasticidade;
 - variâncias diferentes.
-

Quando:

$$p > 0.05$$

Conclusão:

- não há evidências de heterocedasticidade.
-

ANOVA

O que a ANOVA faz?

Compara médias entre grupos.

Objetivo

Verificar se:

pelo menos uma média difere das outras.

Hipóteses

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$$

H_1 : pelo menos uma média difere

Interpretação

Quando:

$$p < 0.05$$

Conclusão:

- existem diferenças estatísticas entre grupos.
-

Quando:

$$p > 0.05$$

Conclusão:

- não há evidência suficiente de diferença.
-

ANOVA de Welch

Por que usar Welch?

A ANOVA clássica exige:

- homocedasticidade.

Como o teste de Levene pode indicar heterocedasticidade:
utiliza-se Welch.

Vantagem

Welch é mais robusta quando:

- variâncias são diferentes.
-

Qui-Quadrado

O que ele faz?

Verifica associação entre variáveis categóricas.

Exemplo do trabalho

COVID vs Delivery.

Hipóteses

H_0 : as variáveis são independentes

H_1 : há associação

Interpretação

Quando:

$$p < 0.05$$

Conclusão:

- existe associação estatística.
-

Quando:

$$p > 0.05$$

Conclusão:

- não há evidência de associação.
-

Correlação de Pearson

O que ela mede?

Mede associação linear entre variáveis quantitativas.

Coefficiente

$$-1 \leq \rho \leq 1$$

Interpretação

Próximo de +1

Forte associação positiva.

Exemplo:

peso aumenta e IMC aumenta.

Próximo de -1

Forte associação negativa.

Exemplo:

uma variável sobe e outra desce.

Próximo de 0

Baixa associação linear.

Correlação NÃO implica causalidade

Esse é um dos pontos mais importantes.

Correlação NÃO prova causa e efeito.

Exemplo

Duas variáveis podem:

- crescer juntas;
 - mas serem influenciadas por outro fator.
-

Boxplot

O que ele mostra?

- mediana;
 - dispersão;
 - quartis;
 - possíveis outliers.
-

Interpretação

Caixa muito alta

Maior dispersão.

Caixa pequena

Menor dispersão.

Pontos isolados

Possíveis outliers.

Histograma

O que ele mostra?

Distribuição da variável.

Interpretação

Simétrico

Indício de normalidade.

Assimétrico

Indício de não normalidade.

Caudas longas

Possíveis outliers.

Outliers

O que são?

Valores muito distantes dos demais.

Possíveis causas

- erro de coleta;
 - erro de digitação;
 - comportamento raro real.
-

Importância

Outliers podem:

- distorcer médias;
 - afetar modelos;
 - alterar testes estatísticos.
-

Interpretação Geral do Trabalho

O que o trabalho mostrou?

A análise indicou:

- mudanças comportamentais durante a pandemia;
 - relação entre atividade física e IMC;
 - associação entre COVID e delivery;
 - forte relação entre peso e IMC.
-

Limitações

Dados autorreportados

As pessoas podem:

- errar informações;
 - omitir dados;
 - estimar incorretamente.
-

Ausência longitudinal

Os dados representam:

um recorte no tempo.

Não acompanham evolução individual.

Perguntas que podem surgir

“Por que usar Shapiro?”

Para avaliar normalidade.

“Por que usar Levene?”

Para verificar igualdade das variâncias.

“Por que Welch?”

Porque Welch é robusta à heterocedasticidade.

“Correlação implica causalidade?”

Não.

“O que significa rejeitar H_0 ?”

Significa:

os dados observados são improváveis sob a hipótese nula.

“O que significa não rejeitar H_0 ?”

Não significa provar que ela é verdadeira.

Apenas:

não houve evidência suficiente contra ela.

Encerramento

O trabalho combinou:

- estatística descritiva;
- testes inferenciais;

- análise gráfica;
- interpretação estatística.

O foco principal não é apenas calcular resultados, mas:
entender o comportamento dos dados e interpretar corretamente as conclusões estatísticas.